

Práctica 1 - Entrega 1

Argumentos causales alternativos e incertidumbre.

Docente: Gustavo Landfried

Inferencia Bayesiana Causal
2do cuatrimestre 2026 - UNSAM

Índice

1. Modelo Base vs Modelo Monty Hall	1
1.1. Implementar la distribución de creencia conjunta como producto de las distribuciones condicionales del modelo	2
1.2. Simular datos con el modelo Monty Hall	3
1.3. Calcular la predicción a priori que hace cada uno de los modelos sobre la totalidad de la base de datos simulada	4
1.4. Calcular la predicción de los datos con la contribución de todos los modelos.	5
1.5. Calcular y graficar el posterior de los modelos sobre los datos simulados	5
1.6. Calcular la predicción típica que hace el modelo de los episodios.	5
1.7. Diferencia de predicciones a priori sobre los datos en órdenes de magnitud.	6

1. Modelo Base vs Modelo Monty Hall

Los datos no hablan por sí solos, son interpretados a través de modelos causales. En la figura 1 se ve la especificación gráfica de dos argumentos causales alternativos: a la izquierda el modelo “Base” y a la derecha modelo “Monty Hall”. Esos dibujos (redes bayesianas) son la especificación matemática completa de los argumentos causales alternativos. El producto de las distribuciones de probabilidad condicional de cada variable produce la distribución de probabilidad conjunta a partir de la cual podemos sacar todas las conclusiones: predecir un dato con la contribución de todas las hipótesis ($P(d) \sum_h P(d, h)$), o actualizar la creencia de una hipótesis dada la información disponibles ($P(h|d) = P(h, d)/P(d)$). Una misma distribución conjunta se puede descomponer de muchas formas alternativas. Una red bayesiana es causal solo cuando la descomposición se corresponde con la semántica causal, es decir, las distribuciones de probabilidad condicional representan mecanismos causales probabilísticos entre causas y efectos. Los modelos Base y Monty Hall son ejemplos de redes bayesianas causales.




Figura 1: Modelos causales probabilísticos alternativos representados mediante la notación de redes bayesianas causales.

Las redes bayesianas causales encapsulan todas las hipótesis de investigación que se utilizan para interpretar los datos y sacar conclusiones sobre las hipótesis ocultas. La única restricción que supone el modelo Base (izquierda) es que la pista s no puede señalar la caja en la que se encuentra el regalo: $s \neq r$. El modelo Monty Hall (derecha) incluye esa restricción y agrega una más: la pista s tampoco puede señalar la caja que ya reservaste: $s \neq c$. Abajo de cada uno aparece una distribución *a posteriori* sobre la posición del regalo luego de haber reservado la caja 1 y luego de que nos hayan mostrado que en la caja 2 no estaba el regalo: $P(r|s = 2, c = 1)$. Podemos ver que los argumentos causales alternativos nos conducen a conclusiones distintas, distribuye la creencia del regalo dada la información disponible de forma distinta: el modelo Base $P(r|s = 2, c = 1) = [1/2, 0, 1/2]$; el modelo Monty Hall en $P(r|s = 2, c = 1) = [1/3, 0, 2/3]$. ¿Qué argumento causal tiene la razón?. ¿Con qué conclusión nos debemos quedar?.

Las reglas de la probabilidad son el sistema de razonamientos para contextos de incertidumbre. Así como usamos las reglas de la probabilidad para evaluar las hipótesis al interior de los modelos causales, los modelos causales también son hipótesis sobre las que tenemos incertidumbre y por lo tanto pueden ser evaluadas mediante la aplicación estricta de las reglas de la probabilidad. El objetivo de esta guía es actualizar nuestras creencias sobre modelos alternativos luego de observar un conjunto de datos: $P(\text{Modelo}|\text{Datos})$.

$$P(\text{Modelo}|\text{Datos}) = \frac{P(\text{Datos}|\text{Modelo})P(\text{Modelo})}{P(\text{Datos})}$$

Para ello deberemos calcular:

- La predicción que hace el modelo sobre los potenciales datos: $P(\text{Datos}|\text{Modelo})$
- La predicción de los datos realizada con la contribución de todos los modelos: $P(\text{Datos})$
- La creencia previa “honesta” sobre los modelos: $P(\text{Modelo})$

1.1. Implementar la distribución de creencia conjunta como producto de las distribuciones condicionales del modelo

La figura 1 no es solo un dibujo ilustrativo, contiene todas nuestras hipótesis: define exactamente la distribución de creencias a priori sobre todos los posibles universos paralelos, $P(r, c, s|M)$. Ella se puede reconstruir haciendo el producto de los mecanismos causales probabilísticos de cada

variable, representada mediante una distribución de probabilidad condicional.

$$\underbrace{P(r, c, s|M_0)}_{\text{Prior conjunto hipótesis en } M_0} = \underbrace{P(r|M_0)P(c|M_0)P(s|r, M_0)}_{\text{Relaciones causales probabilísticas propuestas por el modelo } M_0}, \quad \underbrace{P(r, c, s|M_1)}_{\text{Prior conjunto hipótesis en } M_1} = \underbrace{P(r|M_1)P(c|M_1)P(s|r, c, M_1)}_{\text{Relaciones causales probabilísticas propuestas por el modelo } M_1}$$

Ambos modelos suponen que r y c son variables independientes. Maximizando incertidumbre entre las 3 opciones obtenemos distribuciones condicionales a priori sobre r y c iguales en ambos modelos.

$$P(r|M) = P(r) = \frac{r=0}{1/3} \mid \frac{r=1}{1/3} \mid \frac{r=2}{1/3} \quad P(c|M) = P(c) = \frac{c=0}{1/3} \mid \frac{c=1}{1/3} \mid \frac{c=2}{1/3}$$

La única diferencia entre los modelos aparece en la distribución condicional sobre la pista. El modelo Base M_0 supone que s depende únicamente de r (con la restricción $s \neq r$), mientras que el modelo Monty Hall M_1 considera que s depende tanto de r como de c (con las restricciones $s \neq r$ y $s \neq c$). Maximizando incertidumbre entre las opciones disponibles obtenemos la siguiente distribución condicional para el modelo Base (que solo depende del regalo r).

$$P(s|r, M_0) =$$

	$s = 0$	$s = 1$	$s = 2$
$r = 0$	0	1/2	1/2
$r = 1$	1/2	0	1/2
$r = 2$	1/2	1/2	0

Notar que hay una distribución de probabilidad por cada uno de los condicionales (cada regalo), lo que implica que (los renglones) tiene que integrar 1.

En el modelo Monty Hall el condicional depende de dos variables, el regalo r y la caja elegida c . Para simplificar, mostraremos los valores cuando $c = 0$.

$$P(s|r, c = 0, M_1) =$$

$(c = 0)$	$s = 0$	$s = 1$	$s = 2$
$r = 0$	0	1/2	1/2
$r = 1$	0	0	1
$r = 2$	0	1	0

Nuevamente, notar que cada renglón suma 1 pues cada condicional representa una distribución de probabilidad distinta.

Ejercicio: Implementar la distribuciones condicionales $p_r(r)$, $p_c(c)$, $p_{s-M_0}(s)$, $p_{s-M_1}(s)$ y la distribución conjunta $p_{rcs-M}(r, c, s, m)$.

1.2. Simular datos con el modelo Monty Hall

Antes de evaluar los modelos necesitamos un conjunto de datos que provengan de la realidad causal subyacente. Podríamos buscar los datos reales del programa de televisión Monty Hall y revisar si efectivamente el modelo Monty Hall propuesto es mejor que el modelo Base. Aquí vamos a suponer que nuestro modelo Monty Hall representa perfectamente la realidad causal subyacente y vamos a generar los datos a partir de él.

Las redes bayesianas causales son siempre modelos generativos a partir de los cuales se pueden simular datos. *Ancestral sampling* es el proceso ir generando una a una las variables a partir de su distribución de probabilidad condicional. Primero se genera los valores de las variables raíz que no tienen causas. Y luego se van generando las variables para las cuales ya tienen definidas el valor de todas sus causas. Cuando generamos un valor por cada variables tenemos una muestra completa y consistente con las relaciones causales y probabilísticas definidas por la red.

Ejercicio: implementar la función `simular(T=16)`. El objetivo es generar un conjunto de datos con $T = 16$ episodios a partir de la distribución conjunta del modelo Monty Hall (M_1).

$$\text{Datos} = [(c_0, s_0, r_0), \dots, (c_{T-1}, s_{T-1}, r_{T-1})]$$

Para generar valores de las variables pueden usar `np.random.choice(a,p)`, donde **a** debe ser una lista con todos los posibles valores de la variable y **p** debe ser la distribución de probabilidad, una lista con una probabilidad por posible valor.

1. Elegí una semilla (*seed*) para reproducibilidad.
2. Para cada episodio t , muestreá primero las variables raíz (por ejemplo r_t y c_t) desde sus priors.
3. Dado (r_t, c_t) , muestreá la pista s_t usando el mecanismo $P(s_t | r_t, c_t, M_1)$ (mismo condicional que definiste arriba).
4. Guardá el episodio en el orden en que se observarían los datos (c_t, s_t, r_t) , y repetí hasta completar T episodios.

1.3. Calcular la predicción a priori que hace cada uno de los modelos sobre la totalidad de la base de datos simulada

Ahora sí, podemos calcular la predicción del conjunto de datos que hace cada uno de los modelos con la contribución de todas sus hipótesis internas.

$$P(\text{Datos} = \underbrace{\{(c_0, s_0, r_0)\}}_{\text{Primer episodio}}, \underbrace{\{(c_1, s_1, r_1)\}}_{\text{Segundo episodio}}, \dots, \underbrace{\{(c_{T-1}, s_{T-1}, r_{T-1})\}}_{\text{T-ésimo episodio}} | \text{Modelo})$$

Los modelos causales expresados en la figura 1 proponen relaciones causales probabilísticas entre las variables al interior de un episodio. En principio, estos modelos sólo están definidos para un único episodio. Para extenderlos a T episodios vamos a considerar que contamos con T repeticiones de esa misma estructura causal. Las repeticiones se especifican gráficamente mediante el uso de “placas”.




Figura 2: Extensión de los modelos causales alternativos a T episodios mediante la notación de “placas”. El subíndice t representa las repeticiones.

Dado que entre episodios no hay flechas que vinculen entre sí las estructuras causales, lo que ocurra en un episodio no influye en lo que ocurra en otro (los episodios son independientes entre sí). Esto permite descomponer la predicción sobre el conjunto de datos sobre todos los episodios como el producto de las predicciones que los modelos hacen al interior de cada episodio.

$$P(\text{Datos} | \text{Modelo}) = \prod_{t \in \{0, \dots, T-1\}} P(c_t | \text{Modelo}) P(s_t | c_t, \text{Modelo}) P(r_t | s_t, c_t, \text{Modelo})$$

Ejercicio: Implementar la predicción que el modelo hace de un episodio $P(c_t, s_t, r_t \mid M) = P(c_t \mid M) P(s_t \mid c_t, M) P(r_t \mid s_t, c_t, M)$, `pEpisodio_M(c,s,r,m)`, e implementar la predicción que el modelo hace de todo el conjunto de datos $P(\text{Datos} \mid M)$, `pDatos_M(datos,m)`.

1.4. Calcular la predicción de los datos con la contribución de todos los modelos.

Ahora vamos a calcular la distribución de probabilidad sobre los modelos causales alternativos dada la evidencia disponible. En el denominador del posterior tenemos la predicción de la predicción de los datos, $P(\text{Datos})$ hecha con la contribución de todos los modelos.

$$P(\text{Datos}) \stackrel{\text{Regla de la suma}}{=} \sum_{\text{Modelo}} P(\text{Modelo}, \text{Datos}) \stackrel{\text{Regla de la producto}}{=} \sum_{\text{Modelo}} \underbrace{P(\text{Datos} \mid \text{Modelo})}_{\text{Predicción hecha por el modelo}} \underbrace{P(\text{Modelo})}_{\text{Creencia en el modelo}} \quad (1)$$


Ejercicio: Implementar el prior de los modelos $P(\text{Modelo})$, `pM(m)`, y la predicción con la contribución de todos los modelos $P(\text{Datos})$, `pDatos(datos)`.

1.5. Calcular y graficar el posterior de los modelos sobre los datos simulados

Ahora sí. Tenemos todos los elementos necesarios para calcular el posterior de los modelos.

$$P(\text{Modelo} \mid \text{Datos}) = \frac{P(\text{Modelo}, \text{Datos})}{P(\text{Datos})}$$

Ejercicio: Implementar el posterior de los modelos, `pM_Datos(m,datos)` y graficar como cambia el posterior en el tiempo. El gráfico resultante se debería ver de la siguiente forma:



1.6. Calcular la predicción típica que hace el modelo de los episodios.

Dado que la predicción sobre un conjunto de datos se descompone como el producto de las predicciones, la predicción típica es su media geométrica, la raíz N -ésima de la predicción sobre todo el conjunto de datos (donde N es el tamaño del conjunto de datos $N = |\text{Datos}|$).

$$\text{Predicción típica} := \underbrace{P(\text{Datos} = \{d_1, d_2, \dots, d_N\} \mid M)^{1/N}}_{\text{Media geométrica}} \quad (2)$$

Decimos que es típica justamente porque al reemplazar cada una de las predicciones individuales por el valor de la media geométrica volvemos a obtener exactamente el valor de la predicción sobre

todo el conjunto de datos.

$$\begin{aligned} P(\text{Datos} = \{d_1, d_2, \dots, d_N\} | M) &= P(d_1 | M) P(d_2 | d_1, M) \dots \\ &= \prod_{i \in \{1, \dots, N\}} \text{Predicción típica} = \text{Predicción típica}^N \end{aligned} \quad (3)$$

Ejercicio: Implementar la función que calcula la predicción típica `prediccion_tipica(exponente)`.

1.7. Diferencia de predicciones a priori sobre los datos en órdenes de magnitud.

Para comparar modelos también se suele reportar la diferencia de predicciones en órdenes de magnitud.

$$\frac{P(M_i | \text{Datos})}{P(M_j | \text{Datos})} = \frac{P(\text{Datos} | M_i) P(M_i)}{P(\text{Datos} | M_j) P(M_j)} = \underbrace{\frac{P(\text{Datos} | M_i)}{P(\text{Datos} | M_j)}}_{\text{Bayes factor}} \quad (4)$$

Al dividir el valor a posteriori de los dos modelos alternativos i y j se cancela el denominador constante del teorema de Bayes, $P(\text{Datos})$. Esa es la primera transformación que hacemos. Además, en el caso de que tengamos un prior uniforme entre modelos, $P(M_i) \stackrel{*}{=} P(M_j)$, también se cancelan los priors y la comparación del posterior de los modelos se reduce a la comparación de sus predicciones, $P(\text{Datos} | M)$. Este cociente entre predicciones de los modelos se conoce como *Bayes factor*.

Debido a que las predicciones sobre grandes conjuntos de datos se acercan a 0 rápidamente (lo cual no puede ser representado en una computadora) conviene trabajar en escala logarítmica para ir sumando los exponentes de las predicciones (que es factible de representar en la computadora). Además llevar la comparación en esa escala tiene la ventaja de hacer que la comparación sea simétrica (diferencia de predicción en órdenes de magnitud).

$$\log_{10} \underbrace{\frac{P(\text{Datos} | M_i)}{P(\text{Datos} | M_j)}}_{\text{Bayes factor}} = \underbrace{\log_{10} P(\text{Datos} | M_i) - \log_{10} P(\text{Datos} | M_j)}_{\text{Diferencia predictiva en órdenes de magnitud}} \quad (5)$$

Para interpretar el significado del exponente del Bayes factor (5) es importante recordar que la verosimilitud de los modelos $P(\text{Datos} | M)$ funciona como filtro de la creencia previa. En base 10, una diferencia de un orden de magnitud significa que uno de los modelos preservó 10 veces más creencia que el otro, dos ordenes de magnitud significa que un modelos preservó 100 veces más creencia que el otro, y así sucesivamente. Aunque estos números parezcan extraordinarios, cuatro órdenes de magnitud se considera en el límite de una diferencia no concluyente. Cuando las bases de datos crecen, la diferencia en órdenes de magnitud continúan creciendo, por lo que es normal ver diferencia de 10000, pero en órdenes de magnitud! En esos casos, para ganar intuición es útil calcular la predicción “típica” (que veremos en la próxima sección).

Ejercicio: Implementar la comparación del desempeño predictivo de los modelos Base (M_0) y Monty Hall (M_1) usando el Bayes factor en escala logarítmica, `log_bayes_factor(datos, m_i, m_j)`.